



IIC2343 - Arquitectura de Computadores (I/2026)

Guía de ejercicios: Floats

Ayudantes: Alberto Maturana (alberto.maturana@uc.cl), Mario Rojas (mario.denzel@estudiante.uc.cl), Ignacio Gajardo (gajardo.ignacio@uc.cl)

Pregunta 1: Representación de números Reales

- Suponga que posee dos representaciones para números reales que desea utilizar para almacenar el número binario $0,00010111_b$.
 - **Representación 1 (Punto Fijo):** 1 bit de signo; 2 bits de parte entera; y 6 bits de parte fraccional.
 - **Representación 2 (Punto Flotante):** 1 bit de signo de significante; 4 bits de significante (sin bit implícito); 1 bit de signo de exponente; y 3 bits de exponente.

¿Cuál de estas representaciones presenta una menor pérdida de precisión para almacenar el número?
- Suponga que se crea el tipo de dato **arquiFloat** de 32 bits a partir del nuevo estándar “IIC2343” para representar números de punto flotante. A diferencia del tipo de dato **float** del estándar IEEE754, este posee el siguiente formato:
 - Un bit de signo de significante.
 - Un bit de signo de exponente.
 - 10 bits de exponente no desfasado.
 - 20 bits de significante normalizado con bit implícito.

Compare los dos estándares respondiendo las siguientes preguntas:

- Señale una ventaja y una desventaja del tipo de dato **arquiFloat** respecto del tipo de dato **float**.
- Señale cómo se representa el resultado de la operación $2^{22} + 7$ en formato **float** y **arquiFloat**. ¿Existe pérdida de precisión en alguno de los casos?

Solución:

1.1) Para este número, es recomendable hacer uso de la representación de **punto flotante**.

Su representación normalizada equivale a $1,0111 \times 10^{-4}$, por lo que, considerando el formato de 4 bits de significativo sin bit implícito, se busca almacenar la secuencia fraccionaria 10111, por la cantidad de bits que tenemos para el significativo. La secuencia resultante es: $0_{\text{Signo}}1_{\text{sig}}1011_{\text{Significante}}1_{\text{Signo.exp}}100_{\text{Exp}}$.

De este resultado se deduce que **existe pérdida de precisión de 1 bit**, ya que el significativo disponible (4 bits) no es suficiente para representar el número normalizado (10111).

En cambio, en el formato de **punto fijo**, se intenta almacenar 0,00010111. Dado que solo dispone de 6 bits para la parte fraccional, la secuencia almacenada es: $0_{\text{Signo}}00_{\text{Entero}}000101_{\text{Fracción}}$.

Se observa que en esta última representación se pierden los 2 bits menos significativos (11 al final de la cadena original), lo que equivale a una pérdida de precisión de $2^{-7} + 2^{-8}$. Por lo tanto, el formato de punto flotante es más preciso para este valor.

1.2.a) Una ventaja es que **arquiFloat** posee un rango mayor respecto a los números que puede representar dada su cantidad de bits de exponente. En este caso, el mayor exponente representable es $111111110_b = 1022$ (si se asume la reserva para los valores infinitos y con bit de signo positivo), que es significativamente mayor al exponente máximo de **float** igual a 127. Por otra parte, una desventaja es la pérdida de precisión. En este caso, si incluimos el bit implícito, **arquiFloat** puede representar números de hasta 21 bits en comparación a **float** que puede representar números de hasta 24 bits.

1.2.b) El número que se busca representar, haciendo la suma entre 2^{22} y 7 con notación científica, es igual a $1,00000000000000000000111 \times 10^{00010110}$. A continuación, veremos cómo se almacena en cada representación:

- **float:** El número es positivo (bit de signo igual a cero) y el exponente desfasado es igual a $22 + 127 = 149$. Por lo tanto, se almacena la secuencia $0_{\text{signo}}10010101_{\text{exp.}}00000000000000000000001110_{\text{sig.}}$. No existe pérdida de precisión.

- **arquiFloat:** Tanto el número como su exponente son positivos (bits de signo iguales a cero). Por lo tanto, se almacena la secuencia:

$0_{\text{signo}}0_{\text{signo exp.}}0000010110_{\text{exp.}}000000000000000000000001_{\text{sig.}}$

Se pierden dos bits de precisión, por lo que se pierde el valor exacto del número: se redondea a $2^{22} + 4$.

Pregunta 2: Conversión a IEEE-754

Transforme los siguientes números al formato IEEE-754 (32 bits):

1. 127
2. 3,140625
3. -1,6875
4. 0,1015625
5. -2,40625

Solución:

1. La representación binaria de 127 es $1111111b = 1,111111b \times 2^6$. Por lo tanto, su exponente desfasado es $127 + 6 = 133 = 10000101b$ y su bit de signo es 0, dado que el número es positivo. La representación es:

0 10000101 111111000000000000000000

2. Para 3,140625, la parte entera es $11b$ y la decimal es $0,140625 = 1/8 + 1/64 = 0,001001b$. El número completo es $11,001001b = 1,1001001b \times 2^1$.

- Signo: $0b$ (positivo).
- Exponente desfasado: $127 + 1 = 128 = 10000000b$.
- Mantisa: $100100100000000000000000b$.

La representación es:

0 10000000 100100100000000000000000

3. Para $-1,6875$, la parte entera es $1b$ y la decimal es $0,6875 = 1/2 + 1/8 + 1/16 = 0,1011b$. El número completo es $-1,1011b \times 2^0$.

- Signo: $1b$ (negativo).
- Exponente desfasado: $127 + 0 = 127 = 01111111b$.
- Mantisa: $101100000000000000000000b$.

La representación es:

1 01111111 101100000000000000000000

4. Para $0,1015625$, la parte entera es $0b$ y la decimal es $1/16 + 1/32 + 1/128 = 0,0001101b$. Normalizado es $1,101b \times 2^{-4}$.

- Signo: $0b$ (positivo).
- Exponente desfasado: $127 + (-4) = 123 = 01111011b$.
- Mantisa: $101000000000000000000000b$.

La representación es:

0 01111011 101000000000000000000000

5. Para $-2,40625$, la parte entera es $10b$ y la decimal es $0,40625 = 1/4 + 1/8 + 1/32 = 0,01101b$. El número completo es $-10,01101b = -1,001101b \times 2^1$.

- Signo: $1b$ (negativo).
- Exponente desfasado: $127 + 1 = 128 = 10000000b$.
- Mantisa: $001101000000000000000000b$.

La representación es:

1 10000000 001101000000000000000000

Pregunta 3: Conversión a decimal

Transforme los siguientes números de su representación hexadecimal a binario. Luego, interpretándolos con el estándar IEEE-754, indique su valor en decimal.

1. 0x42AA1000
2. 0xC25A8000
3. 0x7F90100B
4. 0x41D48000
5. 0xFF800000
6. 0x45800180

Solución:

Recuerde que, para la transformación de hexadecimal a binario, se debe reemplazar el valor de cada dígito hexadecimal a su representación binaria usando 4 bits

1. Al separar el valor en binario del número en signo, exponente y mantisa, según el estándar IEEE-754, se obtiene que:

0 10000101 010101000010000000000000

Con esto, es posible deducir que:

- **Signo:** El valor del bit de signo es 1, por lo tanto, el número es negativo (-)
- **Exponente:** El valor del exponente desfasado es $10000101b = 133$, esto implica que el exponente es: $133 - 127 = 6$.
- **Significante:** El valor del significante es $1,01010100001b$.

Finalmente, se tiene que la representación del número es:

$$1,01010100001b \times 2^6 = 1010101,00001b = 85,03125$$

2. Al separar el valor en binario del número en signo, exponente y mantisa, según el estándar IEEE-754, se obtiene que:

1 10000100 101101010000000000000000

Con esto, es posible deducir que:

- **Signo:** El valor del bit de signo es 1, por lo tanto, el número es negativo (-)
- **Exponente:** El valor del exponente desfasado es $10000100b = 132$, esto implica que el exponente es: $132 - 127 = 5$.
- **Significante:** El valor del significante es $1,10110101b$.

Finalmente, se tiene que la representación del número es:

$$-1,10110101b \times 2^5 = -110110,101b = -54,625$$

3. Al separar el valor en binario del número en signo, exponente y mantisa, según el estándar IEEE-754, se obtiene que:

0 11111111 00100000001000000001011

Con esto, es posible deducir que:

- **Signo:** El valor del bit de signo es 0, por lo tanto, el número es positivo (+)
- **Exponente:** El valor del exponente desfasado es $11111111b$, entonces, necesariamente se trata de un caso especial.

- **Significante:** El valor del significante es $1,00100000001000000001011b$.

Dado que la parte fraccionaria del significante tiene al menos un bit igual a 1, se tiene que la representación del número es NaN.

4. Al separar el valor en binario del número en signo, exponente y mantisa, según el estándar IEEE-754, se obtiene que:

0 10000011 101010010000000000000000

Con esto, es posible deducir que:

- **Signo:** El valor del bit de signo es 0, por lo tanto, el número es positivo (+)
- **Exponente:** El valor del exponente desfasado es $10000011b = 131$, esto implica que el exponente es: $131 - 127 = 4$.
- **Significante:** El valor del significante es $1,10101001b$.

Finalmente, se tiene que la representación del número es:

$$1,10101001b \times 2^4 = 11010,1001b = 26,5625$$

5. Al separar el valor en binario del número en signo, exponente y mantisa, según el estándar IEEE-754, se obtiene que:

1 11111111 000000000000000000000000

Con esto, es posible deducir que:

- **Signo:** El valor del bit de signo es 1, por lo tanto, el número es negativo (-)
- **Exponente:** El valor del exponente desfasado es $11111111b$, entonces, necesariamente se trata de un caso especial.
- **Significante:** El valor del significante es $0b$.

Dado que la parte fraccionaria del significante solo tiene bits iguales a 0 y el signo es negativo, se tiene que la representación del número es $-\infty$.

6. Al separar el valor en binario del número en signo, exponente y mantisa, según el estándar IEEE-754, se obtiene que:

0 10001011 000000000000000110000000

Con esto, es posible deducir que:

- **Signo:** El valor del bit de signo es 0, por lo tanto, el número es positivo (+)
- **Exponente:** El valor del exponente desfasado es $10001011b = 139$, esto implica que el exponente es: $139 - 127 = 12$.
- **Significante:** El valor del significante es $1,00000000000000011b$.

Finalmente, se tiene que la representación del número es:

$$1,0000000000000011\text{b} \times 2^{12} = 1000000000000,0011\text{b} = 4096,1875$$

Pregunta 4: Suma y multiplicación de Floats

Realice las siguientes operaciones planteadas a continuación:

1. **(I1 2024-1)** Interprete los números $A = 0\text{x}7\text{F}800000$ y $B = 0\text{x}40000000$ y súmelos.
2. Interprete los números $A = 0\text{x}42300000$ y $B = 0\text{x}41\text{B}80000$ y súmelos.
3. Interprete los números $A = 0\text{x}40200000$ y $B = 0\text{x}421\text{B}0000$ y súmelos.
4. Multiplique los números 21,5 y 6 en el formato IEEE-754.
5. Multiplique los números 6,25 y -7,5 en el formato IEEE-754.
6. Interprete los números $0\text{x}430\text{C}0000$ y $0\text{x}7\text{fC}00000$ y multiplíquelos.

Solución:

1. Las representaciones de los números 0x7F800000 y 0x40000000 en binario son:

- $A = 0111111110000000 \ 0000000000000000b$.
 - **Signo:** 0b $\rightarrow$ positivo.
 - **Exponente:** 10000000b $\rightarrow 255 - 127 = 128$.
 - **Significante:** 00000000000000000000000b $\rightarrow 1,0b$.
 - **Valor:** $+\infty$
- $B = 0100000000000000 \ 0000000000000000b$.
 - **Signo:** 0b $\rightarrow$ positivo.
 - **Exponente:** 10000000b $\rightarrow 128 - 127 = 1$.
 - **Significante:** 00000000000000000000000b $\rightarrow 1,0b$.
 - **Valor:** $(1,0 \times 10^1)b = 1b = 2$.

De lo anterior, se deduce que la operación a realizar es igual a $\infty \times 2$, lo que en formato float se traduce como $+\infty = 0x7F800000$.

2. Las representaciones de los números 0x42300000 y 0x41b80000 en binario son:

- $A = 0x42300000 = 0 \ 10000100 \ 011000000000000000000000$
 - **Signo:** 0b $\rightarrow$ Positivo.
 - **Exponente:** 10000100b $\rightarrow 132 - 127 = 5$.
 - **Significante:** 01100000000000000000000b $\rightarrow 1,011b$.
 - **Valor:** $1,011b \times 2^5$
- $B = 0x41B80000 = 0 \ 10000011 \ 011100000000000000000000$
 - **Signo:** 0b $\rightarrow$ Positivo.
 - **Exponente:** 10000011b $\rightarrow 131 - 127 = 4$.
 - **Significante:** 01110000000000000000000b $\rightarrow 1,0111b$
 - **Valor:** $1,0111b \times 2^4$

Al momento de aplicar el algoritmo de la suma los exponentes de ambos números deben ser iguales. Para esto, se debe hacer *shift right* al número con menor exponente, en este caso B. Por lo tanto, la representación de B queda como:

$$B = 0,10111b \times 2^5$$

Ahora, con los exponentes igualados, es posible realizar la suma de los significantes:

$$\begin{array}{r} 1,01100 \\ + \ 0,10111 \\ \hline = \ 10,00011 \end{array}$$

Por otro lado, el exponente del resultado es el mismo que el de los operandos (luego de igualar). Por lo tanto, el resultado de la suma es:

$$10,00011b \times 2^5 = 1000011b = 2^6 + 2^1 + 2^0 = 67$$

3. Las representaciones de los números 0x40200000 y 0x421B0000 en binario son:

- $A = 0x40200000 = 0\ 10000000\ 0100000000000000000000$
 - **Signo:** 0b $\rightarrow$ Positivo.
 - **Exponente:** 10000000b $\rightarrow 128 - 127 = 1$.
 - **Significante:** 010000000000000000000000b $\rightarrow 1,01b$.
 - **Valor:** $1,01b \times 2^1$
- $B = 0x421B0000 = 0\ 10000100\ 001101100000000000000000$
 - **Signo:** 0b $\rightarrow$ Positivo.
 - **Exponente:** 10000011b $\rightarrow 132 - 127 = 5$.
 - **Significante:** 001101100000000000000000b $\rightarrow 1,0011011b$
 - **Valor:** $1,0011011b \times 2^5$

Para igualar los exponentes, se deben hacer 4 *shift right* a A. Por lo tanto, la representación de A queda como:

$$A = 0,000101b \times 2^5$$

Ahora, con los exponentes igualados, es posible realizar la suma de los significantes:

$$\begin{array}{r} 0,0001010 \\ + 1,0011011 \\ \hline = 1,0100101 \end{array}$$

Por otro lado, el exponente del resultado es el mismo que el de los operandos (luego de igualar). Por lo tanto, el resultado de la suma es:

$$1,0100101b \times 2^5 = 101001,01b = 2^5 + 2^3 + 2^0 + 2^{-2} = 41,25$$

4. Las representaciones de los números 21,5 y 6 en el formato IEEE-754 son:

- $21,5 = 0\ 10000011\ 010110000000000000000000$
- $6 = 0\ 10000001\ 100000000000000000000000$

Para realizar la multiplicación, se hace uso del algoritmo visto en clases. En primer lugar, es posible observar que los exponentes no desfasados de los números son 4 y 2, respectivamente. Por lo tanto, para obtener el exponente del resultado se utiliza la siguiente fórmula: $exp_a + exp_b + \text{desfase}$:

$$4 + 2 + 127 = 133 = 10000101b$$

Luego, se deben multiplicar los significantes sin considerar las comas de los operandos:

$$\begin{array}{r} 1,01011 \times 1,1 \\ 1\ 01011 \\ 10\ 1011 \\ \hline = 100\ 00001 \end{array}$$

Luego, la coma se desplaza tanto como indique la suma de las posiciones del multiplicando y el multiplicador, en este caso 6. Por lo tanto, el resultado de la multiplicación de los significantes es $10,000001b$ y el número resultante es: $10,000001b \times 2^6$.

Dado que el número no se encuentra normalizado, es necesario hacer un *shift left*. Esto implica que el valor del exponente aumentará en 1, pasando a $134 = 10000110b$, mientras que el valor de la mantisa será $1,0000001b$.

Finalmente, con esta información es posible escribir la representación del resultado en el estándar IEEE-754, la cual es:

0 10000110 000000100000000000000000

El cual representa el valor 129, es decir, la multiplicación de $21,5 \times 6$.

5. Las representaciones de los números 6,25 y -7,5 en el formato IEEE-754 son:

- $6,25 = 0 \ 10000001 \ 100100000000000000000000$
- $-7,5 = 1 \ 10000001 \ 111000000000000000000000$

En primer lugar, es posible observar que los ambos exponentes no desfasados son 2. Por lo tanto, el exponente del resultado es:

$$exp_a + exp_b + \text{desfase} = 2 + 2 + 127 = 131 = 10000011b$$

Luego, se deben multiplicar los significantes sin considerar las comas de los operandos:

$$\begin{array}{r} 1,1001 \times 1,111 \\ 1 \ 1001 \\ 11 \ 001 \\ 110 \ 01 \\ 1100 \ 1 \\ = 10111 \ 0111 \end{array}$$

Luego, la coma se desplaza tanto como indique la suma de las posiciones del multiplicando y el multiplicador, en este caso 7. Por lo tanto, el resultado de la multiplicación de los significantes es $10,1110111b$ y el número resultante es: $10,1110111b \times 2^4$.

Dado que el número no se encuentra normalizado, es necesario hacer un *shift left*. Esto implica que el valor del exponente aumentará en 1, pasando a $132 = 10000100b$, mientras que el valor de la mantisa será $1,01110111b$. Es importante notar que, a partir de los signos del operando, el resultado de la multiplicación será negativo.

Finalmente, con esta información es posible escribir la representación del resultado en el estándar IEEE-754, la cual es:

1 10000100 011101110000000000000000

El cual representa el valor -46.875, es decir, la multiplicación de $6,25 \times -7,5$.

6. Las representaciones de los números 0x430c0000 y 0x7fc00000 en binario son:

- 0x430c0000 = 0 10000110 000110000000000000000000

- 0x7fc00000 = 0 11111111 100000000000000000000000

Si interpretamos los números con el estándar, es posible observar que corresponden a: 140 y NaN respectivamente, con ello es posible determinar que no se podrían operar los valores.